

System detekcji manipulacji

System detekcji dezinformacji z wyjaśnialną sztuczną inteligencją (XAI)

Vadym Abrosimov | 43995

Promotor: dr inż. Andrzej Burda

Kierunek: Informatyka



UNIWERSYTET VIZJA

www.vizja.pl

Dlaczego istniejące rozwiązania nie wystarczą?

BERT i modele klasyfikacyjne

Zwracają wyłącznie **wynik liczbowy** — brak jakiegokolwiek wyjaśnienia podjętej decyzji.

GPT-4 i modele chmurowe

Ograniczenia moderacji treści, **wysokie koszty API** oraz ryzyko naruszenia prywatności danych.

Ręczny fact-checking

Weryfikacja jednego artykułu zajmuje **godziny pracy** eksperta — metoda całkowicie nieskalowalna.

Luka technologiczna

Żadne z dostępnych rozwiązań nie łączy jednocześnie: lokalnego wdrożenia, wyjaśnialności oraz adaptacji do nowych danych bez zewnętrznych zależności.

Co realizuje System detekcji manipulacji?

1

Detekcja technik manipulacji

Automatyczna identyfikacja **11 technik dezinformacji** w polskojęzycznych tekstach — od manipulowania emocjami po wyolbrzymianie faktów

2

Wyjaśnialne uzasadnienia

System generuje nie tylko etykietę klasyfikacyjną, lecz także **czytelne uzasadnienie** decyzji zrozumiałe dla analityka.

3


Możliwość douczania

System może być **rozszerzany o nowe przykłady** i ponownie dostrajany, gdy pojawiają się nowe typy manipulacji.

Architektura systemu



Tryb 1: analiza tekstu



Tryb 2: douczanie eksperckie

Przykład działania systemu

Input: fragment artykułu → Output: wykryte techniki manipulacji + uzasadnienie decyzji

W ostatnim roku w naszym mieście wzrosła liczba rowerzystów i jednocześnie wzrosła liczba wypadków drogowych. To jasno pokazuje, że rowerzyści są główną przyczyną tych wypadków. Dlatego powinniśmy ograniczyć ruch rowerowy w centrum

Wybiórczość (Cherry Picking)

Autor stosuje technikę wyboru fragmentów informacji (CHERRY_PICKING), ponieważ prezentuje tylko jedno zjawisko - wzrost liczby wypadków drogowych - bez uwzględnienia innych potencjalnych czynników wpływających na te wypadki. Tekst nie podaje informacji o tym, czy wzrosła liczba rowerzystów w tym samym czasie lub czy inne grupy użytkowników dróg również przyczyniły się do wzrostu wypadków.

Technologie i narzędzia



Modele językowe

Bielik-4.5B-Instruct (produkcja) oraz **Qwen-2.5-7B** jako model nauczyciela w procesie destylacji wiedzy.



Inferencja lokalna

Ollama / llama.cpp z formatem GGUF (8-bit) zapewnia szybką, prywatną inferencję bez połączenia z chmurą.



Fine-tuning

Unsloth / QLoRA (kwantyzacja 4-bit) trenowane na Google Colab T4 — bez potrzeby dedykowanej infrastruktury GPU.



Warstwa aplikacyjna

FastAPI + WebSocket po stronie backendu, **React + Vite** na frontendzie, **SQLite** do śledzenia rekordów treningowych, środowisko **WSL2**.

NIEZAWODNOŚĆ

Mechanizmy zwiększające niezawodność systemu

01

Walidacja struktury odpowiedzi

02

Automatyczna naprawa formatu

03

Normalizacja tagów

Wskaźnik poprawnej struktury

96%+

PSR (Parse Success Rate) – skuteczność odczytu ustrukturyzowanych odpowiedzi modelu po zastosowaniu pełnego potoku naprawczego.

Wyniki eksperymentalne (N = 1 521)

Metryka	Brak adaptera	Prototyp	XAI
PSR	20%	99,9%	96,3%
F1	0,10	0,49	0,28
Exact Match	38%	73%	73%



Prototyp F1 = 0,49 konkurencyjne wobec raportowanych w literaturze, mimo zastosowania lokalnego modelu 4,5B



Podatek od wyjaśnialności: dodanie uzasadnień XAI obniża F1 do 0,28 — koszt interpretowalności przy zachowaniu dokładności strukturalnej na poziomie 73%.

Osiągnięcia i kierunki rozwoju

Zrealizowane cele

- Kompletny system: inferencja, douczanie, ewaluacja i **hot-swap modelu** w jednej platformie.
- Działanie w pełni **lokalne** — bez zależności od API chmurowych, z gwarancją prywatności danych.
- Adaptacja do nowych danych w **ciągu minut** dzięki QLoRA i zautomatyzowanej pętli MLOps.

Planowany rozwój

- **GPU powyżej 24 GB** — trening modeli 13B+ dla wyższego F1 bez kompromisu wyjaśnialności.
- **LLM-as-a-Judge** — automatyczna ocena jakości uzasadnień bez udziału człowieka.
- **RBAC i bias mitigation** — kontrola dostępu oraz redukcja stronniczości klasyfikatora.