

Міністерство освіти і науки України
Харківський національний університет радіоелектроніки

Факультет Навчально-науковий центр заочної форми навчання
(повна назва)

Кафедра Штучного інтелекту
(повна назва)

Звіт з передатестаційної практики

Система виявлення дезінформації та логічних помилок у медіатекстах з
використанням пояснюваного штучного інтелекту (ХАІ)
(тема роботи)

Виконав:

здобувач вищої освіти гр. ІТШЗ-22-1 Абросімов В.П. Абросімов В.П.
(підпис) (прізвище, ініціали)

Керівник практики від підприємства _____ Чала Л.Е.
(підпис) (прізвище, ініціали)

Керівник практики від ЗВО _____ Погурська М.М.
(підпис) (прізвище, ініціали)

КАЛЕНДАРНИЙ ПЛАН

№	Назва етапів роботи	Строк / термін виконання етапів роботи	Примітка
1.	Отримання завдання	06.04.2026	виконано
2.	Аналіз предметної галузі та огляд існуючих рішень (GPT-4, BERT)	10.04.2026	виконано
3.	Вивчення теоретичних основ пояснювального ШІ (XAI) та LLM	15.04.2026	виконано
4.	Дослідження технологічного стеку (Unsloth, Ollama, Bielik)	20.04.2026	виконано
5.	Розробка архітектури системи та методики навчання (QLoRA)	25.04.2026	виконано
6.	Оформлення звіту з практики та щоденника	27.04.2026	виконано

Здобувач вищої освіти

Абросімов В.П.
(підпис)

Абросімов В.П.
(прізвище, ініціали)

Керівник практики від підприємства

(підпис)

Чала Л.Е.
(прізвище, ініціали)

Керівник практики від ЗВО

(підпис)

Погурська М.М.
(прізвище, ініціали)

РЕФЕРАТ

Звіт з передатестаційної практики: 13 с., 0 рис., 10 джерел.

BIELIK, LLM, MLOPS, QLORA, XAI, ВЕЛИКІ МОВНІ МОДЕЛІ, ДЕЗІНФОРМАЦІЯ, МАНІПУЛЯЦІЯ, ПОЯСНЮВАЛЬНИЙ ШТУЧНИЙ ІНТЕЛЕКТ.

Об'єкт дослідження – процес автоматичного виявлення дезінформації та технік маніпуляції у текстових медіа-матеріалах.

Предмет дослідження – методи обробки природної мови (NLP) та архітектури пояснювального ШІ для інтерпретації рішень нейронних мереж.

Мета роботи – проектування та реалізація інформаційної системи для ідентифікації маніпуляцій з генерацією текстового обґрунтування логіки рішення через механізм Chain-of-Thought.

Методи дослідження – аналіз існуючих підходів до детекції фейків (GPT-4, BERT), методи тонкого налаштування LLM (QLoRA) та методологія дистиляції знань «Teacher-Student».

Результати та їх новизна – розроблено архітектуру системи на базі моделі Bielik-4.5B та впроваджено модуль «Human-in-the-Loop» для донавчання за участю експерта,. Для оптимізації використано техніку QLoRA, що дозволило адаптувати модель на споживчому обладнанні. Новизна полягає у створенні локальної системи, яка забезпечує прозорість прийняття рішень через механізм Natural Language Explanations (NLE).

Сфера застосування – інформаційна безпека, медіамоніторинг та інструменти підтримки прийняття рішень для журналістів і аналітиків.

ЗМІСТ

Вступ.....	5
1 Аналіз предметної галузі та теоретичні основи.....	7
1.1 Аналіз існуючих підходів до детекції дезінформації.....	7
1.2 Теоретичні основи пояснювального ШІ (XAI) у текстах	8
2 Проєктування та імплементація системи.....	9
2.1 Методологія підготовки даних та генерація NLE.....	9
2.2. Тонке налаштування моделі (Supervised Fine-Tuning).....	9
2.3. Архітектура інференсу та модуль MLOps	10
Висновки	11
Перелік джерел посилання	12

ВСТУП

Актуальність теми. У сучасних умовах глобальної цифровізації соціальні мережі та онлайн-медіа стали основним джерелом інформації для мільйонів користувачів. Однак це призвело до безпрецедентного зростання обсягів дезінформації, пропаганди та технік маніпуляції свідомістю. Наявні методи боротьби з дезінформацією стикаються з двома критичними проблемами. По-перше, комерційні великі мовні моделі (як-от GPT-4) є закритими системами, що створює загрозу приватності та залежність від корпоративної цензури. По-друге, класичні класифікатори (на базі архітектури BERT) працюють як «чорна скринька», видаючи результат без логічного обґрунтування, що не дозволяє користувачеві зрозуміти причину класифікації контенту як маніпулятивного.

Розробка системи, яка поєднує в собі потужність великих мовних моделей із принципами пояснювального штучного інтелекту (Explainable AI, XAI), є надзвичайно актуальною. Такий підхід дозволяє не лише автоматизувати процес перевірки фактів, а й підвищувати медіаграмотність населення, надаючи зрозумілі текстові пояснення логіки прийняття рішень (Natural Language Explanations).

Мета дослідження полягає у проєктуванні та програмній реалізації інформаційної системи для автоматичного виявлення маніпуляцій та логічних помилок у текстах, яка здатна генерувати розгорнуті пояснення через механізм Chain-of-Thought. Важливою частиною мети є створення автономного рішення, яке може функціонувати локально на споживчому обладнанні, забезпечуючи незалежність від зовнішніх API.

Задачі дослідження:

- провести порівняльний аналіз існуючих підходів до детекції дезінформації, виявивши недоліки статичних моделей та закритих комерційних систем;

- розробити методологію підготовки якісного набору даних із використанням дистиляції знань за принципом «Teacher-Student» для навчання моделі пояснювальної аргументації;

- виконати тонке налаштування (Fine-tuning) базової мовної моделі Bielik-4.5B із застосуванням техніки QLoRA для оптимізації обчислювальних ресурсів;

- спроектувати архітектуру системи за принципом MLOps Loop, що передбачає можливість ітеративного донавчання моделі за участю експерта (Human-in-the-Loop);

- реалізувати прототип вебзастосунку з функціоналом візуалізації знайдених маніпуляцій та модулем інженерного управління інференсом через сервер Ollama.

Об’єкт дослідження – процес автоматичної ідентифікації технік маніпуляції та дезінформаційних наративів у текстових матеріалах засобів масової комунікації.

Предмет дослідження – методи обробки природної мови (NLP), архітектури великих мовних моделей (LLM) та алгоритми пояснювального ШІ для генерації раціональних обґрунтувань рішень нейронної мережі.

Практичне значення. Розроблена система може бути використана як інструмент підтримки прийняття рішень для журналістів, аналітиків або звичайних користувачів соцмереж. Впровадження механізму «Retrain Button» дозволяє адаптувати модель до нових типів маніпуляцій протягом декількох хвилин, що забезпечує життєздатність системи в умовах постійної еволюції дезінформаційних стратегій.

1 АНАЛІЗ ПРЕДМЕТНОЇ ГАЛУЗІ ТА ТЕОРЕТИЧНІ ОСНОВИ

1.1 Аналіз існуючих підходів до детекції дезінформації

Сучасний ринок технологій боротьби з дезінформацією в медіа-просторі характеризується розривом між високою потужністю закритих корпоративних рішень та обмеженою масштабованістю академічних проєктів. У ході дослідження було виділено три ключові категорії систем: комерційні великі мовні моделі, класичні класифікатори на базі архітектури BERT, спеціалізовані портали фактчекінгу.

Комерційні великі мовні моделі (GPT-4, Gemini): ці рішення пропонують найвищий рівень логічного висновування (reasoning), проте їх використання в системах інформаційної безпеки обмежене через модель «закритого API». Це створює критичні ризики для приватності даних, оскільки весь контент аналізується на сторонніх серверах. Крім того, ці моделі мають жорсткі фільтри безпеки (over-refusal), які часто блокують аналіз політично чутливих текстів, що складають основу дезінформаційних кампаній. Також спостерігається втрата локального контексту, де глобальні моделі не здатні розпізнати специфічну іронію або культурні нюанси певної країни.

Класичні класифікатори на базі архітектури BERT (напр. PL-RoBERTa): Дані моделі є стандартом в академічних колах завдяки високій швидкості та низьким вимогам до обчислювальних ресурсів. Головним недоліком є їхня «непояснюваність». Модель видає лише імовірнісну оцінку (наприклад, 0.95), не надаючи жодних аргументів. Це не дозволяє користувачеві зрозуміти причину класифікації та не сприяє розвитку медіаграмотності. Окрім того, BERT-моделі є статичними: для їх адаптації до нових наративів дезінформації потрібен повний цикл перенавчання фахівцями.

Спеціалізовані портали фактчекінгу (напр. Demagog): Ці платформи базуються на глибокій експертизі людей-аналітиків. Хоча вони є еталоном якості, такі рішення абсолютно не піддаються масштабуванню в реальному часі. Перевірка однієї новини може займати кілька годин, тоді як дезінформація в соціальних мережах поширюється за хвилини.

1.2 Теоретичні основи пояснювального ШІ (XAI) у текстах

Ключовою теоретичною базою даного проєкту є концепція Natural Language Explanations (NLE). На відміну від традиційного ШІ, який працює як «чорна скринька», системи з підтримкою XAI мають генерувати текстове обґрунтування своїх рішень. Це базується на методології Rationale Generation, що передбачає виділення конкретних фрагментів тексту (доказів), які прямо вказують на використання маніпулятивних технік. Використання механізму Chain-of-Thought (CoT) дозволяє моделі вибудовувати логічний ланцюжок перед фінальним висновком, що значно підвищує рівень довіри до системи.

2 ПРОЄКТУВАННЯ ТА ІМПЛЕМЕНТАЦІЯ СИСТЕМИ

2.1 Методологія підготовки даних та генерація NLE

Одним із найбільш трудомістких етапів реалізації системи стала відсутність якісних наборів даних із текстовими поясненнями маніпуляцій. Для вирішення цієї проблеми було спроектовано пайплайн дистиляції знань за принципом «Teacher-Student».

Роль вчителя (Teacher Model): використано потужну модель Qwen-2.5-7B-Instruct, яка здатна до глибокого логічного аналізу. Вона обробляла збірку маніпуляцій MIPD і для кожного прикладу генерувала логічне пояснення, чому саме цей фрагмент є маніпулятивним.

Технічна реалізація: процес генерації було автоматизовано через скрипти Python, що реалізують механізм Hard-Constraint Generation. Це включало валідацію виходу моделі на відповідність формату JSON та автоматичні повторні запити (retry loop) у разі помилок. Таким чином було створено базу з понад 10,000 синтетичних прикладів високої якості, що містять як мітку класу, так і розгорнуте обґрунтування (reasoning).

2.2. Тонке налаштування моделі (Supervised Fine-Tuning)

Для реалізації локальної системи було обрано модель Bielek-4.5B-Instruct, яка поєднує достатню потужність із можливістю роботи на користувацькому обладнанні. Процес навчання базувався на технології QLoRA, яка дозволяє тренувати лише низькорангові адаптери, зберігаючи основні ваги моделі замороженими в 4-бітному форматі.

Конфігурація навчання: встановлено параметр `max_seq_length = 16384` з використанням масштабування RoPE, що дозволяє моделі аналізувати довгі статті цілком.

Оптимізація: використано бібліотеку Unsloth, що забезпечило прискорення навчання вдвічі при зниженні споживання відеопам'яті на 60%. Також застосовано метод Completion Only LM, де модель навчалася генерувати виключно аналітичну відповідь, ігноруючи вхідний текст у функції втрат, що прискорило збіжність алгоритму.

2.3. Архітектура інференсу та модуль MLOps

Інженерна реалізація системи передбачає повну автономність. Використано сервер Ollama, який забезпечує динамічне завантаження навчених адаптерів (Runtime Adapter Loading) поверх базової моделі у форматі GGUF. Центральним елементом системи є MLOps Loop, що реалізує концепцію «Human-in-the-Loop».

Backend (FastAPI): керує процесами черги завдань та взаємодіє з ізольованим середовищем WSL для запуску процесів донавчання.

Панель експерта (React): дозволяє завантажувати нові зразки дезінформації. Після натискання кнопки «Retrain» система автоматично запускає тренування адаптера LoRA, проводить бенчмаркінг (PSR, Exact-Match, F1-score) та відображає результати експерту.

Евалюація: впроваджено систему Heuristic Recovery, яка виправляє типові помилки моделі (напр., помилки у ключах JSON) перед видачею результату, що підвищує стабільність системи до >95%.

Дана архітектура дозволяє оперативно реагувати на нові інформаційні загрози, адаптуючи модель до свіжих наративів дезінформації протягом декількох хвилин без залучення програмістів.

ВИСНОВКИ

У результаті виконання передатестаційної практики було спроектовано та реалізовано комплексний прототип системи детекції дезінформації з пояснювальним модулем. Основні досягнення:

Успішно проведено тонке налаштування моделі Bielik-4.5B за допомогою QLoRA, що забезпечило точність класифікації на рівні сучасних академічних моделей при збереженні повної локальності.

Реалізовано архітектуру пояснювального ШІ (XAI), яка генерує аргументацію природною мовою, вирішуючи проблему «чорної скриньки».

Розроблено MLOps-петлю для оперативного донавчання моделі, що дозволяє адаптувати систему до нових типів маніпуляцій за лічені хвилини.

Перспективи розвитку. Надалі планується масштабування системи на серверне обладнання для підтримки більшого контекстного вікна (32k токенів) та впровадження системи автоматичної валідації пояснень за принципом «LLM-as-a-Judge». Таким чином, розроблений інженерний артефакт є готовою базою для повноцінної бакалаврської роботи.

ПЕРЕЛІК ДЖЕРЕЛ ПОСИЛАННЯ

1) ДСТУ 3008:2015 Інформація та документація. Звіти у сфері науки і техніки. Структура та правила оформлювання. *БУДСТАНДАРТ Online - нормативні документи будівельної галузі України*. URL: https://online.budstandart.com/ua/catalog/doc-page.html?id_doc=64463 (date of access: 27.04.2026).

2) ДСТУ 8302:2015 Інформація та документація. Бібліографічне посилання. *Останні новини, нормативи та публікації - ДБНУ - Державні будівельні норми України - норми: ДБН, ДСТУ, СНуП, ГОСТ, СН, ВБН*. URL: https://dbn.co.ua/load/normativy/dstu/dstu_8302_2015/5-1-0-1773 (date of access: 27.04.2026).

3) Харківський нац. ун-т радіоелектроніки. Методичні вказівки до організації виконання та захисту кваліфікаційної роботи за першим (бакалаврським) рівнем вищої освіти спеціальності 122 Комп'ютерні науки. Харків : ХНУРЕ, 2026. 44 с.

4) Attention is all you need. *arXiv.org*. URL: <https://arxiv.org/abs/1706.03762> (date of access: 27.04.2026).

5) Chain-of-Thought prompting elicits reasoning in large language models. *arXiv.org*. URL: <https://arxiv.org/abs/2201.11903> (date of access: 27.04.2026).

6) Miller T. Explanation in artificial intelligence: insights from the social sciences. *Artificial intelligence*. 2019. Vol. 267. P. 1–38. URL: <https://doi.org/10.1016/j.artint.2018.07.007> (date of access: 27.04.2026).

7) Ollama. *Ollama*. URL: <https://ollama.com/> (date of access: 27.04.2026).

8) QLoRA: efficient finetuning of quantized llms. *arXiv.org*. URL: <https://arxiv.org/abs/2305.14314> (date of access: 27.04.2026).

9) Unsloth docs | unsloth documentation. *Unsloth Docs | Unsloth Documentation*. URL: <https://docs.unsloth.ai/> (date of access: 27.04.2026).

10) XAI–Explainable artificial intelligence / D. Gunning et al. *Science robotics*. 2019. Vol. 4, no. 37. P. eaay7120.
URL: <https://doi.org/10.1126/scirobotics.aay7120> (date of access: 27.04.2026).